



基于开源工具搭建小型搜索引擎

王斌 骆卫华 中科院计算所 2006-5-18



提纲

- ♥ 搜索引擎体系结构
- ♥ 小型搜索引擎一目标与功能
- ◆ 数据分析与预处理工具一分词工具ICTCLAS及相关格式处理模块
- ◆ 全文检索工具Lucene简介
- 基于开源工具包的小型搜索引擎的设计与实现
- ◆ 实用化问题
- ♦ 参考文献



提纲

- 炒 搜索引擎体系结构≺
- ◆ 小型搜索引擎一目标与功能
- 采集工具Larbin简介
- ◆ 数据分析与预处理工具一分词工具ICTCLAS及相关格式处理模块
- ◆ 全文检索工具Lucene简介
- 基于开源工具包的小型搜索引擎的设计与实现
- ◆ 实用化问题
- ♦ 参考文献



搜索引擎类型

●目录式搜索引擎



dmoz open directory project

In partnership with AOL > search

about dmoz | suggest URL | help | link | editor login

Search advanced

Business Arts Computers

Movies, Television, Music ... Internet, Software, Hardware... Jobs, Real Estate, Investing...

Games Health Home

Video Games, RPGs, Gambling... Fitness, Medicine, Alternative... Family, Consumers, Cooking...

Kids and Teens News Recreation

Travel, Food, Outdoors, Humor ... Arts, School Time, Teen Life ... Media, Newspapers, Weather...

Science Reference Regional

Maps, Education, Libraries... US, Canada, UK, Europe... Biology, Psychology, Physics ...

Shopping Society Sports

Autos, Clothing, Gifts ... Baseball, Soccer, Basketball ... People, Religion, Issues...

World

Deutsch, Español, Français, Italiano, Japanese, Nederlands, Polska, Dansk, Svenska...

Become an Editor Help build the largest human-edited directory of the web





搜索引擎类型

●元搜索引擎



DÖGPILE

All the best search engines piled into one.



Web Images Audio Video News Yellow Pages White Pages

information retrieval

Go Fetch!

<u>Preferences</u> Advanced Web Search

Web Search Results for "information retrieval"

Best of Breed Results from the Top Search Engines! View Demo

Best of All Search Engines









More Engines

All Search Engines 1 - 20 of 96 (About Results)

1 | 2 | 3 | 4 | 5 Next >

1. Information Retrieval Research - SearchTools Topics

An up-to-date overview of research in the field of information retrieval.

www.searchtools.com/info/info-retrieval.html [Found on Google, MSN Search, Yahoo! Search, Ask.com]

2. UMASS Amherst: Center for Intelligent Information Retrieval

University of Massachusetts research lab focused on efficient access to large, heterogeneous, distributed, text and multimedia databases.

ciir.cs.umass.edu/ [Found on Google, MSN Search, Yahoo! Search, Ask.com]

3. SIGIR: Information Retrieval

"Addresses issues ranging from theory to user demands in the application of computers to the acquisition, organization, storage, retrieval, and distribution ...

WWW.acm.org/sigir/ [Found on Google, MSN Search, Yahoo! Search, Ask.com]

4. Information Retrieval

An online book by CJ van Rijsbergen, University of Glasgow.

www.dcs.gla.ac.uk/Keith/Preface.html [Found on Google, Yahoo! Search, Ask.com]

Are you looking for?

Evaluation of Retrieval

Search Filter: Moderate

Text Retrieval

Search Retrieval

<u>Document Storage And</u> Retr...

Book Indexer

What Is Data Retrieval

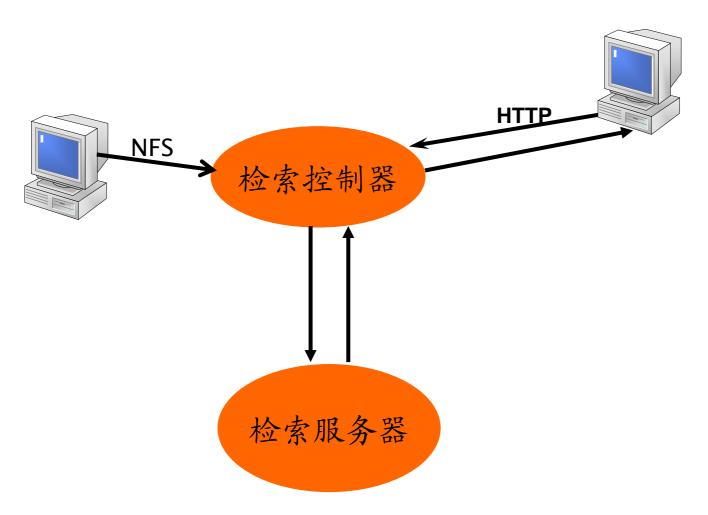


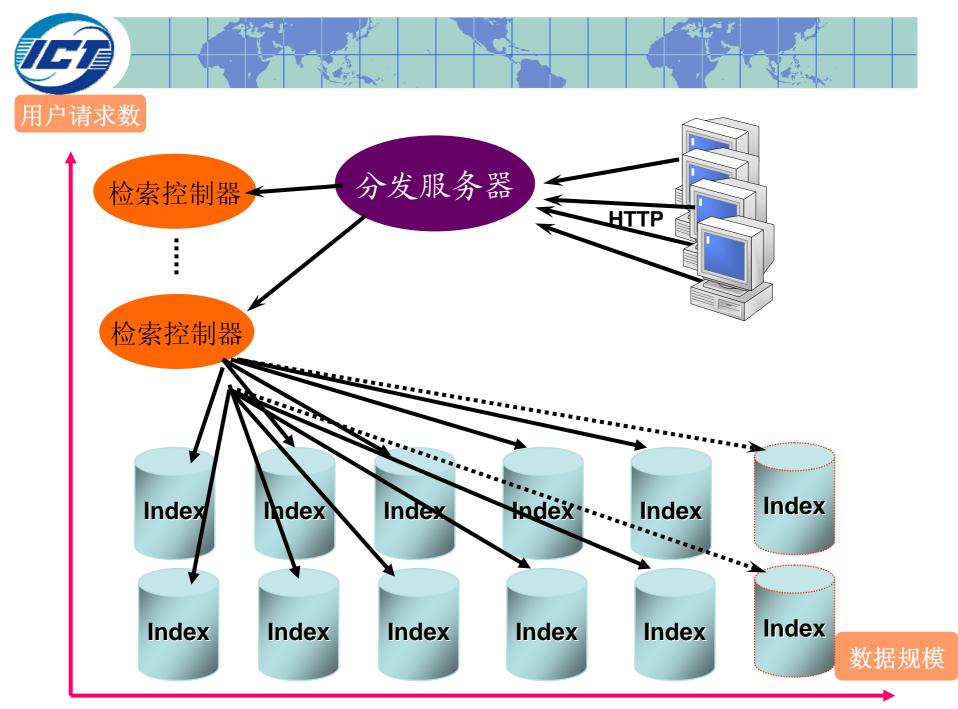
搜索引擎类型

- ●机器人搜索引擎
 - 采集器
 - 分析器
 - ■索引器
 - 索引数据库
 - ■检索器
 - ■用户接口



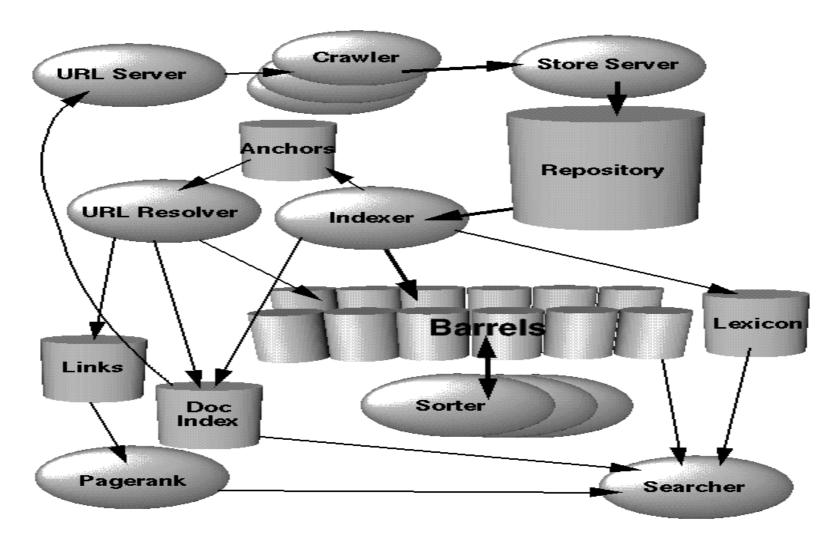
分布式搜索引擎拓扑结构







一个完整的Web搜索引擎





提纲

- ♥ 搜索引擎体系结构
- 小型搜索引擎一目标与功能<
- ◆ 数据分析与预处理工具一分词工具ICTCLAS及相关格式处理模块
- ◆ 全文检索工具Lucene简介
- ♥ 基于开源工具包的小型搜索引擎的设计与实现
- ◆ 实用化问题
- ♦ 参考文献



小型搜索引擎

- ●目标
 - 理解搜索引擎原理
 - 实际搭建一个可运行的实验系统



小型搜索引擎

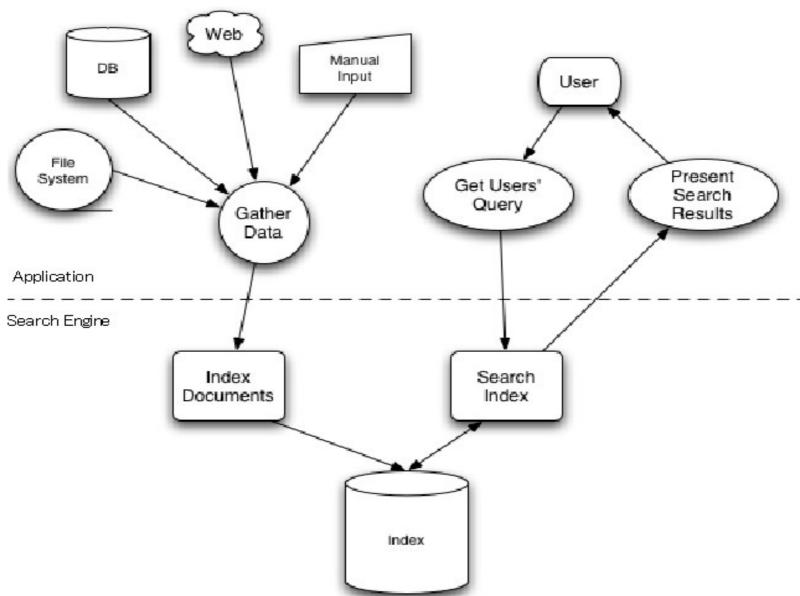
- ●要实现的功能
 - 采集
 - 格式转 换:HTML2TXT,PDF2TXT,DOC2TXT,....
 - 词法处理:分词、词根还原
 - 创建索引
 - 全文检索



小型搜索引擎

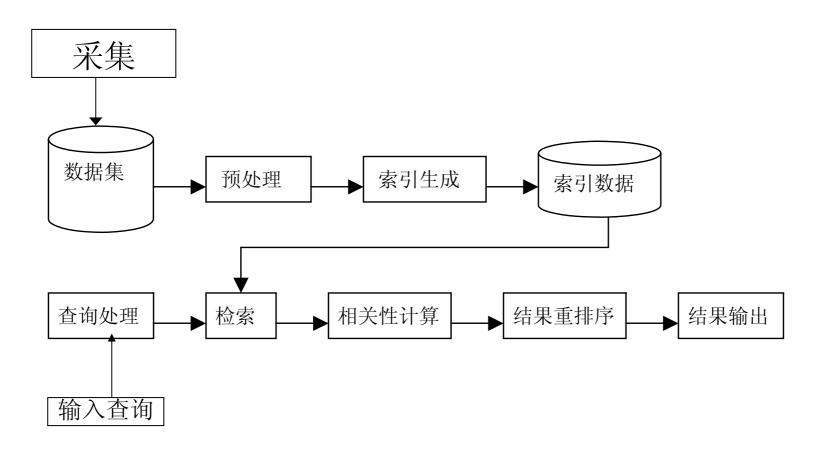
●系统架构







简化的搜索引擎流程





提纲

- ♥ 搜索引擎体系结构
- ◈ 小型搜索引擎一目标与功能
- ◆ 采集工具Larbin简介
- ◆ 数据分析与预处理工具一分词工具ICTCLAS及相关格式处理模块
- ◆ 全文检索工具Lucene简介
- 基于开源工具包的小型搜索引擎的设计与实现
- ◆ 实用化问题
- ♦ 参考文献



Offline Explorer

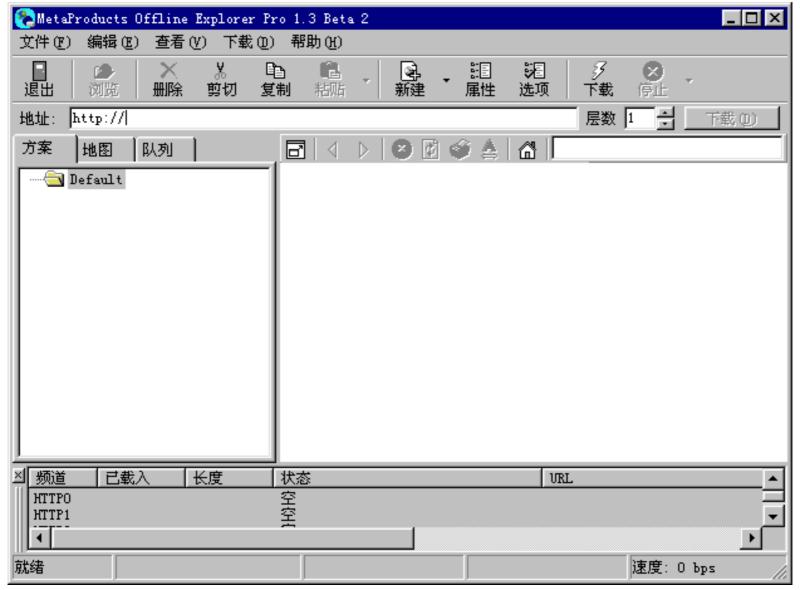
• 小型网页采集器

• 性质: 商业软件

• 作者: Metaproducts

■ 平台: Windows







wget

- 小型网页采集器
- 性质: GNU GPL
- 作者: Hrvoje Niksic
- 平台: Linux



- wget
 - 用法
 - wget [option] [URL]
 - 举例: wget -r -l4 -t0 http://www.ict.ac.cn/

wget -t 0 -w 31 -c -B ftp://user@password:ftp.mtgroup.ict.ac.cn/smt -i filelist.txt -o down.log &



♠ Larbin简介

- 全功能的网页爬虫
- 性质: GNU GPL
- 作者: Sébastien Ailleret
- 网址: http://larbin.sourceforge.net/index-eng.html
- 版本: V2.6.3
- 平台: Linux/FreeBSD
- 后续支持: Nutch



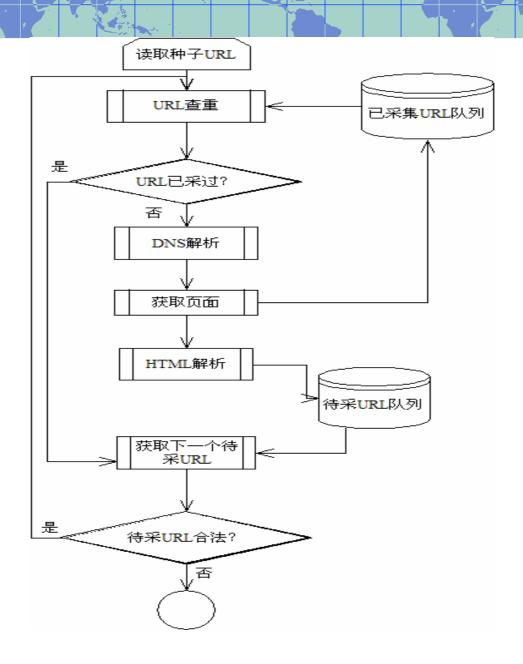
●Larbin简介

- 功能特点
 - 高速,低资源占用
 - 从种子站点开始全网采集
 - 支持远程输入站点采集
 - 限定域/站点/文件类型采集
 - 现场保存和续采
 - 网页去重
 - 状态检测与显示



●Larbin采集流程







- ●Larbin简介
 - 运行
 - ./larbin [-c larbin_conf] [-scratch]
 - 结果存放
 - save/dxxxx/fxxxx ⇔ index
 - 运行状态查看
 - http://server_run_larbin:8081/



- ●配置与部署
 - 配置文件
 - 外部环境变量设置: Larbin.conf
 - 内部变量设置:

options.h

types.h



[Larbin.conf]

- ■From,UserAgent: robot协议
- •httpPort,inputPort: 管理与交互
- ■pagesConnexions,dnsConnexions: 并发采集占用的网络资源
- •depthInSite: 每个站点的采集深度
- ■noExternalLinks: 限定站点
- •waitDuration: 采集间隔
- ■Proxy: 代理
- -StartUrl: 种子Url
- ■limitToDomain: 限定域,如cn, uk等
- ■forbiddenExtensions: 排除文件类型



[options.h]

- #define DEFAULT_OUTPUT // do nothing...
- #define SIMPLE_SAVE // save in files named save/dxxxxxx/fyyyyyy
- #define MIRROR_SAVE // save in files (respect sites hierarchy)
- #define STATS_OUTPUT // do some stats on pages
- #define SPECIFICSEARCH //Set up a specific search
- #define FOLLOW_LINKS //follow links in pages
- #define LINKS_INFO //associate to each page the list of its sons
- #define NO_DUP //suppress duplicate pages
- #define MAXBANDWIDTH 200000



[types.h]

- #define hashSize 64000000 //max number of urls that can be fetched
- #define timeoutPage 30 // default time out
- #define maxPageSize 100000
- #define saveDir "save/" // if we save files, where files are stored
- #define indexFile "index.html" //for MIRROR_SAVE

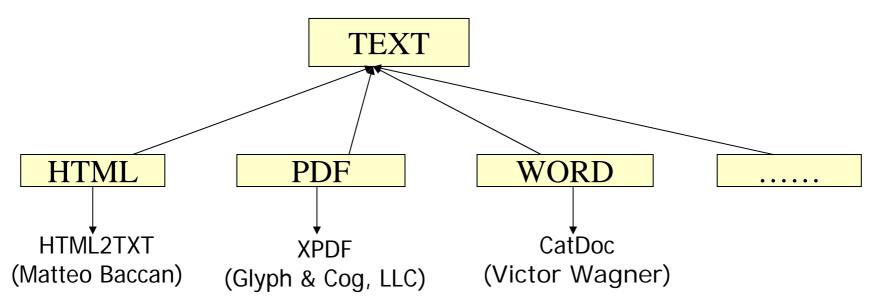


提纲

- ♥ 搜索引擎体系结构
- ♥ 小型搜索引擎一目标与功能
- 采集工具Larbin简介
- ◆数据分析与预处理工具一分词工具ICTCLAS及相关格式处理模块
- ◆ 全文检索工具Lucene简介
- ♥ 基于开源工具包的小型搜索引擎的设计与实现
- ◆ 实用化问题
- ♦ 参考文献



❷格式转换工具





- ♦ 格式转换工具
 - HTML2TXT

接口: void dfConvert(char * Buffer)

XPDF

接口: class PDFDoc

CatDoc

接口: int analyze_format(FILE *f)



- ●中文分词工具一ICTCLAS
 - 中文分词、命名实体识别工具
 - 性质: 自然语言处理开放资源许可证
 - 作者: 张华平
 - Mttp://www.nlp.org.cn/project/project.php?proj_id=6
 - 平台: Windows/Linux
 - SIGHAN第一届国际中文分词比赛Bakeoff第 一名



- ●中文分词工具一ICTCLAS
 - 功能
 - 中文分词
 - ■词性标注
 - ■中文命名实体识别:人名、地名、机构名



数据分析与预处理工具

- ◆ 中文分词工具一ICTCLAS
 - API

初始化: bool ICTCLAS_Init()

运行:

ICTCLAS_ParagraphProcess(char

*sParagraph,char *sResult)

退出: bool ICTCLAS_Exit()

Configure.xml



数据分析与预处理工具

- ●词根还原库一Snowball
 - 用于IR的词根还原库
 - 性质: 开源
 - 作者: Martin Porter
 - 网址: http://snowball.tartarus.org/index.php
 - 平台: Windows/Linux



数据分析与预处理工具

- ゅ 词根还原库ーSnowball
 - API
 - 初始化:
 - struct sb_stemmer * sb_stemmer_new(const char * algorithm, const char * charenc)
 - 运行
 - const sb_symbol * sb_stemmer_stem(struct sb_stemmer *
 stemmer, const sb_symbol * word, int size)
 - 退出void sb_stemmer_delete(struct sb_stemmer * stemmer)



提纲

- ♥ 搜索引擎体系结构
- ◆ 小型搜索引擎一目标与功能
- 采集工具Larbin简介
- ◆ 数据分析与预处理工具一分词工具ICTCLAS及相关格式处理模块
- ◆ 全文检索工具Lucene简介
- 基于开源工具包的小型搜索引擎的设计与实现
- ◆ 实用化问题
- ♦ 参考文献



- ●Lucene简介
 - 完整、高效、易用、可扩展的IR库
 - 性质: Apache License
 - 作者: Doug Cutting
 - 网址: http://lucene.apache.org/
 - 版本: Lucene Java 1.9
 - 平台: 跨平台
 - 支持: Apache Jakarta项目



- ♠Lucene特点
 - ■基于Java实现
 - 可扩展、高性能索引工具:
 - >20M/s@P-M 1.5G
 - 动态内存<=1M
 - 增量式索引
 - 索引数据大小 ≈ (20%~30%)×源数据大小



♣ Lucene功能

- 结果排序一最好结果优先
- 强大的查询表达式处理功能一短语、通配符、模糊 查询等
- 分字段检索
- 指定日期范围检索
- 根据字段排序
- 支持多索引检索与结果合并
- 支持更新与检索同时进行



●Lucene的其他语言版本

- <u>CLucene</u> Lucene implementation in C++
- <u>dotLucene</u> Lucene implementation in .NET
- <u>Lucene4c</u> Lucene implementation in C
- <u>LuceneKit</u> Lucene implementation in Objective-C (Cocoa/GNUstep support)
- <u>Lupy</u> Lucene implementation in Python
- <u>NLucene</u> another Lucene implementation in .NET (out of date)
- Zend Search Lucene implementation in the Zend Framework for PHP
- Plucene Lucene implementation in Perl
- KinoSearch a new Lucene implementation in Perl
- PyLucene GCJ-compiled version of Java Lucene integrated with Python via SWIG
- MUTIS Lucene implementation in Delphi
- Ferret Lucene implementation in Ruby

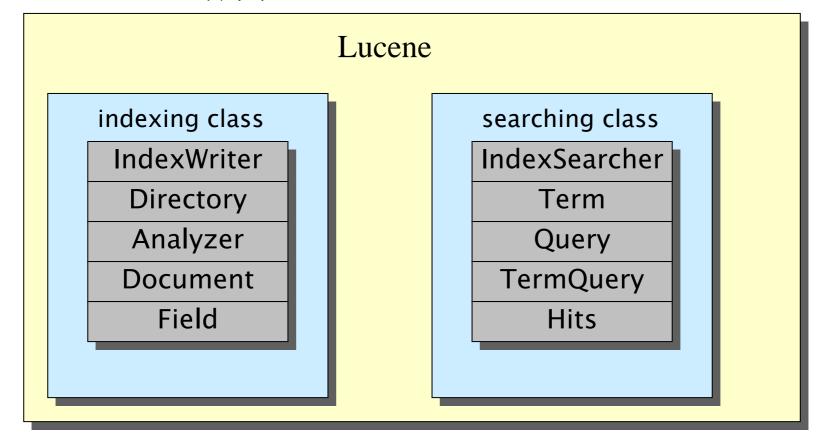


♦ Clucene简介

- Lucene的C++实现
- 作者: Ben van Klinken
- 协议:LGPL
- 网址: http://clucene.sourceforge.net/
- 平台: Windows/Linux/FreeBSD/...
- 版本: 0.9.11(unstable), 0.9.10(stable)
- 与Lucene接口基本一致
- 速度快于Lucene



♠ Lucene结构





- ●Lucene的核心接口
 - ☆索引器
 - IndexWriter:创建与更新索引数据
 - Directory:Lucene索引的位置
 - Analyzer:从文本中提取要建索引的符号
 - Document:字段的集合,可视为虚拟的文档(网页、Email或文本)
 - Field:索引字段,用来建索引的基本单位



●Lucene核心接口

☎ Field使用说明

Field method/type	Analyzed	Indexed	Stored	Example usage	
Field.Keyword(String, String) Field.Keyword(String, Date)		~	~	Telephone and Social Security numbers, URLs, personal names Dates	
Field.UnIndexed (String, String)				Document type (PDF, HTML, and so	
rield.offindexed (Stiffig, Stiffig)			,	on), if not used as a search criteria	
Field.UnStored(String, String)	~	v		Document titles and content	
Field.Text(String, String)	~	~	٨	Document titles and content	
Field.Text(String, Reader)	~	~		Document titles and content	



简单示例一索引

[indexing implementation]

```
void IndexFiles(char* path, char* target)
  StandardAnalyzer analyzer;
  IndexWriter* writer = new IndexWriter(path, &analyzer);
  indexDocs(writer, path);
  writer->optimize();
  writer->close();
  delete writer;
}// IndexFiles
```



简单示例一索引

```
[indexing implementation]
void indexDocs(IndexWriter* writer, char* directory)
  DIR* dir = opendir(directory);
 dirent* de = readdir(dir);
 while (de != NULL)
    if (de.isdirectory())
          indexDocs(writer,de.getfullpath());
     }else{
          Document* doc = new Document();
           doc->add( *Field::Text(_T("path"), de.getfullpath()) );
           doc->add( *Field::Text(_T("contents"),de.gettext()) );
           writer->addDocument(doc);
     }//if
    de = readdir(dir);
  }//while
 closedir(dir);
}// indexDocs
```



●Lucene的核心接口

- ₩检索器
 - IndexSearcher:打开并在索引数据中查找
 - Term:用于检索的基本单位,形式为(字段,值)
 - Query:检索表达式类型
 - TermQuery: 最基本的Query类型,返回在指定字段包含指定关键词的文档
 - Hits:检索结果集



简单示例一检索

[indexing implementation]

```
void SearchFiles(const char* path, char* userquery)
  IndexReader* reader = new IndexReader(path);
  StandardAnalyzer analyzer;
  Query* q = QueryParser::parse(userquery,_"contents",&analyzer);
  Hits* h = s - search(q);
  for (int i=0; i< h>= length(); i++)
     Document* doc = h - > doc(i);
     printf("Result%d: %s\n", i, doc->get("path"));
   }//for
  delete reader;
}// IndexFiles
```



提纲

- ♥ 搜索引擎体系结构
- ◆ 小型搜索引擎一目标与功能
- ◆ 数据分析与预处理工具一分词工具ICTCLAS及相关格式处理模块
- ◆ 全文检索工具Lucene简介
- ●基于开源工具包的小型搜索引擎的设计与实现《
- ◆ 实用化问题
- ♦ 参考文献



- ♥运行采集器
- ◎构造索引器
- ◎构造检索服务器
- ◇构造用户交互接口



- ●运行采集器
 - ■典型设置

[larbin.conf]

From luoweihua@ict.ac.cn

UserAgent larbin_2.6.3

#noExternalLinks

waitDuration 30

depthInSite 5

startUrl http://www.sina.com.cn/



- ●运行采集器
 - ■典型设置

#define saveDir "save/"

```
[options.h]
#define SIMPLE_SAVE
#define FOLLOW_LINKS
#define NO_DUP
#define MAXBANDWIDTH 200000
[types.h]
```



- ●运行采集器
 - ./configure
 - **gmake**
 - ./larbin



- ◇构造索引器
 - Preprocess Webpages(Web Page Path, New Data Path, DocId);
 - Puild_Index_By_Lucece_IndexWriter(New_Data_Path);



●数据预处理

```
void Preprocess Webpages(string Web Page Path, string New Data Path, uint& DocId)
  DIR* dir = opendir(Web_Page_Path);
  dirent* de = readdir(dir);
  while (de != NULL)
    if (de.isdirectory())
            Preprocess_Webpages(de.getfullpath(), New_Data_Path, DocId);
    }else{
            Preprocess EachPage(de.getfullpath(), New Data Path, DocId);
    }//if
    de = readdir(dir);
  }//while
  closedir(dir);
}// Preprocess_Webpages
```



♥数据预处理

```
Preprocess_EachPage(string Page_Path, string New_Data_Path, uint& DocId)
  int Type = GetFileType(Page_Path);
  switch(Type)
    case HTML: Htm2Txt(GetFileText(Page_Path), NewText);
                  break:
    case PDF: Pdf2Txt(GetFileText(Page Path), NewText);
              break;
    case DOC: Doc2Txt(GetFileText(Page Path), NewText);
              break:
    default: break:
  }//switch
  string SegText;
  ICTCLAS_Paragraph(NewText, SegText);
  SnowBall(SegText);
  StoreResult(SegText, DocId++);
}// Preprocess_Webpages
```



◎构造检索服务器

```
void SearchServer()
{
    InitServer();
    StartSocket(server_socket);
    while (true)
    {
        socket client_socket = accept(server_socket);
        beginthread(Search_Daemon, client_socket);
    }//while
    CloseServer();
}//SearchServer
```



◊检索

```
void Search_Daemon(socket client_socket)
{
    GetUserQueryBySocket(buffer);
    DecodeUserQuery(buffer, UserQuery);
    Search_Result_By_Lucene(UserQuery, AllHits);
    EncapsulateResult(AllHits, Result_String);
    ReturnResult(Result_String, client_socket);
}// Search_Daemon
```



- ●用户接口
 - ™ Web浏览器界面
 - ■用户查询请求处理程序



- ♥Web浏览器界面
 - 输入查询表达式

捜索结果	包含以下 全部 的字词	10 项结果	¥	搜索
	包含以下 任何一个 字词			
	不包括 以下字词			



- ♥Web浏览器界面
 - 結果輸出





资讯 论坛 网页目录 **更多**»

网页

(搜索用时 0.15 秒) 约有3,150,000项符合A Survey on Web Information Retrieval Technologies的查询结果,以下是第1-10项。

A Survey on Web Information Retrieval Technologies 的图书搜索结果



Advanced **Web Technologies** and ... - 936 页 Web Technologies Research and ... - 1082 页

A Survey On Web Information Retrieval Technologies - Huang ... - [翻译此页 вета]

Retrieving information from the Web is becoming a common practice for internet users. However, the size and heterogeneity of the Web challenge the effectiveness of classical information retrieval techniques. In this paper, we report the ...

citeseer.ist.psu.edu/336617.html - 26k - 2006年5月15日 - 网页快照 - 类似网页

文档 A Survey On Web Information Retrieval Technologies 上载者 ...

文档, A Survey On Web Information Retrieval Technologies. 上载者, sunjian. 原作者, Lan Huang (State University of New York at Stony Brook). 加入时间, 2002-09-03 17:11:05. 文档介绍 ... www.nlp.org.cn/docs/download.php?doc_id=78 - 3k - 网页快照 - 类似网页

中文自然语言处理开放平台

垃圾邮件"的智能分析、过滤和Rough集讨论(1664 Downloads, 2002-10-08 12:35:56); A survey of IR and filtering Methods(904 Downloads, 2002-09-03 19:07:26); A Survey On Web Information



- ●用户查询请求处理程序
 - ☎ CGI或脚本语言(ASP,PHP,JSP,etc)
 - ■功能
 - ●获取用户查询式:把用户通过Form输入的查询 语句封装发送给检索服务器
 - ②显示结果: 从检索服务器获取结果,缓存并分页 呈现给用户



```
●获取用户查询

$Query_and = $_Get["query_and"];

$Query_or = $_Get["query_or"];

$Query_not = $_Get["query_not"];

$Total_Query = GenerateTotal($Query_and,$Query_or,$Query_not);

$ClientSock = new ClientSocket($Address, $Port);

$ClientSock->send($Total_Query);
```



```
2显示结果
$Result_String = $ClientSock->receive();
$AllResults = DecodeResult($Result_String);
Foreach ($AllResults as $EachResult)
  Echo "DocId:". $EachResult->docid. "<br>";
  Echo "DocPath:" . $EachResult->docpath . "<br/>;
}//Foreach
```



提纲

- ♥ 搜索引擎体系结构
- ◆ 小型搜索引擎一目标与功能
- 采集工具Larbin简介
- ◆ 数据分析与预处理工具一分词工具ICTCLAS及相关格式处理模块
- ◆ 全文检索工具Lucene简介
- 基于开源工具包的小型搜索引擎的设计与实现
- 实用化问题 <
- ♦ 参考文献



实用化问题

- ♥ 系统架构
- ♥ 数据更新策略
- ♦ 格式识别与转换
- 多语种识别与转换
- ♦有针对性的优化策略
- ♥ 结果排序与优化
- 负载均衡
- ♥ 缓存策略
-



参考文献

- Sergey Brin and Lawrence Page. The Anatomy of a Large-Scale Hypertextual Web Search Engine. http://www-db.stanford.edu/~backrub/google.html
- Lan Huang. A Survey on Web Information Retrieval Technologies. http://citeseer.ist.psu.edu/336617.html
- cneie.com. 中文搜索引擎技术揭密: 系统架构.http://www.cneie.cn/news/20064/2006429161655.html
- ◆ 卢亮. Larbin 一种高效的搜索引擎爬虫工具.

 http://www.wespoke.com/archives/000879.php
- Martin Porter. snowball manual. http://snowball.tartarus.org/compiler/snowman.html
- Doug Cutting, Otis Gospodnetic, etc. Overview of Apache Lucene. http://lucene.apache.org/java/docs/
- ERIK HATCHER,OTIS GOSPODNETIC. Lucene in Action. Manning Publications Co. Greenwich CT.



谢谢!